# SP500 特殊时期模型性能分析报告

> ***实验名称:*** *SpecialPeriod_Seed2620*
> ***市场:*** *标普500指数 (^GSPC)*
> ***模型:*** *ARIMA, Bi-RNN, Bi-GRU, Bi-LSTM, PatchTST, Mamba, SNN, Ensemble*
> ***回望窗口:*** *30, 60, 90, 120, 252 个交易日*
> ***预测步长:*** *1天, 5天, 10天*
> ***评估指标:*** *$R^2$(决定系数), RMSE(均方根误差), MAE(平均绝对误差)*

---

## 1. 总体性能概览

### 1.1 各时期预测难度排名（所有模型平均$R^2$）

| 排名 | 时期 | 平均$R^2$ | 平均RMSE | 平均MAE | 样本数 | 难度 |
|---|---|---|---|---|---|---|
| 1 | 2008年金融危机 | **0.7268** | 0.0191 | 0.0144 | 378 | 最易预测 |
| 2 | 2010年欧债危机 | 0.5395 | 0.0096 | 0.0077 | 568 | |
| 3 | 2023年AI浪潮 | 0.3604 | 0.0277 | 0.0235 | 250 | |
| 4 | 2022年加息周期 | 0.2723 | 0.0381 | 0.0321 | 251 | |
| 5 | 2015年中国股灾 | 0.2145 | 0.0117 | 0.0091 | 189 | |
| 6 | 2018年贸易战 | 0.1983 | 0.0155 | 0.0119 | 251 | |
| 7 | 2020年新冠崩盘 | **0.0683** | 0.0438 | 0.0318 | 104 | 最难预测 |

**分析解读**：

- **2008年金融危机 ($R^2$=0.73)**：尽管波动剧烈，但该危机遵循了一个相对清晰的"下跌-触底-反弹"趋势，由可识别的宏观事件（次贷崩溃、TARP救助计划等）所驱动。这种持续性方向运动使得时间序列模型能够有效地进行结构性预测。充足的样本量（378个交易日）也为模型提供了充分的训练/测试信号。
- **2010年欧债危机 ($R^2$=0.54)**：这是一场持续时间较长、具有多个阶段的危机，伴随着可识别的结构性断点（希腊救助、欧洲央行干预等）。最长的持续时间（568个样本）帮助模型学习到了有意义的模式，且相对较低的RMSE（0.0096）说明波动幅度较为温和。
- **2023年AI浪潮 ($R^2$=0.36)**：由AI/大语言模型热潮驱动的趋势性牛市。虽然总体上升趋势可以被捕捉，但突发的板块轮动和新闻驱动的跳跃（如NVIDIA、微软的财报超预期）引入了噪声，限制了模型精度。
- **2022年加息周期 ($R^2$=0.27)**：美联储激进的紧缩周期制造了一个持续性熊市，但伴随着频繁的政策敏感性反转。较高的RMSE（0.038）反映了这一动荡时期的巨大绝对价格波动。
- **2015年中国股灾 ($R^2$=0.21)**：中国股市崩盘对SP500的影响是通过复杂的跨市场传染渠道（资本流动、大宗商品价格、汇率市场）间接传导的，而非直接的国内基本面因素。这种间接传导产生了嘈杂、非平稳的模式。在非COVID时期中最小的样本量（189）进一步限制了模型学习。

- **2018年贸易战 ($R^2$=0.20)**：中美贸易战由不可预测的政治决策驱动（通过Twitter发布的关税公告），造成了与统计外推根本不兼容的政策体制变化。
- **2020年新冠崩盘 ($R^2$=0.07)**：毫无疑问最困难的时期。新冠疫情导致了前所未有的快速下跌（23个交易日内下跌34%），随后是同样迅猛的V型反弹，由大规模财政/货币刺激推动。仅有104个样本且具有极端的非平稳性，所有模型本质上都失效了。RMSE（0.044）在所有时期中最高，反映了巨大的预测误差。

## 1.2 模型总体排名（所有条件下的平均$R^2$）

| 排名 | 模型 | 平均$R^2$ | 平均RMSE | 平均MAE | $R^2$标准差 | 稳定性 |
|---|---|---|---|---|---|---|
| 1 | **ARIMA** | **0.7501** | 0.0146 | 0.0112 | 0.1645 | 最稳定 |
| 2 | Mamba | 0.6367 | 0.0177 | 0.0137 | 0.2937 | |
| 3 | Bi-RNN | 0.6303 | 0.0187 | 0.0145 | 0.1724 | 稳定 |
| 4 | Bi-GRU | 0.5827 | 0.0189 | 0.0141 | 0.2517 | |
| 5 | Ensemble | 0.5687 | 0.0211 | 0.0161 | 0.1906 | |
| 6 | Bi-LSTM | 0.4798 | 0.0211 | 0.0163 | 0.3632 | |
| 7 | SNN | -0.1282 | 0.0342 | 0.0279 | 0.6969 | 不稳定 |
| 8 | PatchTST | **-0.7999** | 0.0427 | 0.0355 | 0.7439 | 最不稳定 |

**分析解读**：

- **ARIMA的统治地位**：ARIMA在每一个时期都取得了最高的$R^2$。这是因为ARIMA直接建模了时间序列的自相关结构。对于短步长预测（H=1），最近的价格是最强的预测因子，而ARIMA的自回归特性能够高效地利用这一点。其在各时期间较低的标准差（0.16）表明了对不同市场环境的鲁棒性。
- **Mamba是最佳深度学习模型**：Mamba的选择性状态空间机制使其能够动态地关注相关的历史信息，同时遗忘噪声。这类似于金融市场同时展现长程依赖（宏观趋势）和短程模式（动量效应）的特性，而Mamba的架构正是为处理这类问题而设计的。
- **Bi-RNN出人意料的稳定性**：尽管是最简单的循环架构，Bi-RNN取得了第二低的标准差（0.17）。其简单性可能起到了正则化的作用，防止了对特定市场环境的过拟合。
- **Bi-LSTM表现不如Bi-GRU/Bi-RNN**：LSTM更复杂的门控机制（3个门 vs GRU的2个门）可能在有限的特殊时期数据中导致过拟合，尤其是在较长的预测步长下。
- **PatchTST的失败**：PatchTST是为多变量长程预测场景设计的。在大多数时期出现负$R^2$，说明它无法捕捉股票预测所需的短程依赖关系。其基于patch的分词方式可能丧失了金融数据所需的细粒度时间分辨率。
- **SNN的不稳定性**：脉冲神经网络基于二值脉冲的计算引入了量化噪声，严重降低了预测质量。其极端的方差（范围：-1.51到0.56）使其不可靠。
- **Ensemble的表现不佳**：Ensemble对所有模型（包括PatchTST和SNN）进行了平均，而这两个模型严重的负$R^2$拖累了整体表现。这说明当成分模型中包含表现极差的模型时，朴素的集成方法可能适得其反。

# 2. 预测步长（Horizon）分析

## 2.1 预测步长对$R^2$的影响

| 预测步长 | 平均$R^2$ | 平均RMSE | 平均MAE |
|---|---|---|---|
| **1天** | **0.5749** | 0.0180 | 0.0142 |
| 5天 | 0.3499 | 0.0238 | 0.0188 |
| 10天 | 0.0953 | 0.0291 | 0.0229 |

## 2.2 各时期在不同预测步长下的$R^2$

| 时期 | H=1 | H=5 | H=10 | 衰减幅度(H=1到H=10) |
|---|---|---|---|---|
| 2008年金融危机 | 0.7563 | 0.7058 | 0.7182 | -5.0%（几乎无衰减） |
| 2010年欧债危机 | 0.6617 | 0.4567 | 0.5002 | -24.4% |
| 2023年AI浪潮 | 0.4899 | 0.4136 | 0.1778 | -63.7% |
| 2022年加息周期 | 0.5399 | 0.3284 | -0.0514 | -109.5%（崩溃） |
| 2015年中国股灾 | 0.4756 | 0.0922 | 0.0758 | -84.1% |
| 2018年贸易战 | 0.5974 | 0.2842 | -0.2868 | -148.0%（崩溃） |
| 2020年新冠崩盘 | 0.5034 | 0.1684 | -0.4668 | -192.7%（崩溃） |

**分析解读**：

- **预测步长是最重要的单一因素**：$R^2$从H=1的0.57下降到H=10的0.10，降幅达83%。这符合金融计量经济学的既有发现：由于误差累积和不确定性增加，预测准确性随预测步长的增加而迅速衰减。
- **2008年危机具有独特的步长韧性**：$R^2$从H=1（0.76）到H=10（0.72）几乎没有变化。这是因为该危机具有强烈的持续性趋势：一旦崩盘开始，动量贯穿了多日窗口。一致的方向性运动意味着即使是10天前瞻的预测也能利用已建立的趋势。
- **2020年新冠和2018年贸易战在H=10时崩溃**：两者在H=10时的$R^2$均为负值（意味着比简单预测均值还差）。新冠崩盘的V型反弹和贸易战由推文驱动的反转，造成了10天前瞻预测在方向上频繁出错的局面。
- **2023年AI浪潮的显著衰减**：虽然H=1（0.49）尚可，但H=10降至0.18。AI热潮存在微观层面的轮动（AI芯片制造商、软件、云服务提供商之间的板块切换），这些在短期内可预测，但在中期不可预测。

### 2.3 各时期、各预测步长下的最佳深度学习模型

| 时期 | H=1 | H=5 | H=10 |
|---|---|---|---|
| 2008年金融危机 | Bi-GRU (0.9864) | Bi-LSTM (0.9489) | Mamba (0.9019) |
| 2010年欧债危机 | Bi-GRU (0.9639) | Bi-LSTM (0.8729) | Bi-RNN (0.8301) |
| 2015年中国股灾 | Mamba (0.8997) | Bi-GRU (0.5739) | Bi-RNN (0.3939) |
| 2018年贸易战 | Mamba (0.8744) | Mamba (0.4903) | Bi-RNN (0.2654) |
| 2020年新冠崩盘 | Bi-RNN (0.7639) | Bi-RNN (0.5068) | Bi-RNN (-0.1485) |
| 2022年加息周期 | Mamba (0.9042) | Mamba (0.7593) | Mamba (0.4949) |
| 2023年AI浪潮 | Mamba (0.9561) | Bi-GRU (0.8339) | Bi-GRU (0.6662) |

**分析解读**：

- **H=1由Mamba主导（7个时期中的4个）**：Mamba的状态空间机制擅长捕捉短程依赖关系，使其成为大多数市场环境下最佳的1天预测器。
- **H=5呈现混合格局**：没有单一模型占主导地位，表明中期预测在不同市场条件下需要不同的归纳偏置。
- **H=10偏向Bi-RNN（7个时期中的4个）**：对于更长的预测步长，更简单的架构似乎具有更好的泛化能力。Bi-RNN的最小参数化起到了隐式正则化的作用，防止了复杂模型在长步长预测中常见的过拟合。
- **Mamba在2022年加息周期的所有步长中都表现最佳**：美联储的加息周期具有强烈的结构性信号（预定的FOMC会议、前瞻性指引），Mamba的选择性状态空间能够将其有效地建模为长程依赖关系。

---

## 3. 回望窗口（Window Size）分析

### 3.1 窗口大小对$R^2$的影响

| 窗口大小 | 平均$R^2$ | 平均RMSE |
|---|---|---|
| 30 | 0.3769 | 0.0224 |
| 60 | 0.3585 | 0.0237 |
| 90 | 0.3218 | 0.0239 |
| **120** | **0.3829** | 0.0229 |
| 252 | 0.2600 | 0.0253 |

## 3.2 窗口大小 x 预测步长的$R^2$（所有模型和时期的平均值）

| 窗口 \ 步长 | H=1 | H=5 | H=10 |
|---|---|---|---|
| 30 | 0.6310 | 0.3430 | 0.1566 |
| 60 | 0.5941 | 0.3347 | 0.1466 |
| 90 | 0.5273 | 0.3085 | 0.1298 |
| **120** | 0.5937 | **0.4158** | 0.1391 |
| 252 | 0.5282 | 0.3475 | **-0.0956** |

**分析解读**：

- **窗口大小的影响相对较小**，与预测步长和模型选择相比。最佳（W=120，$R^2$=0.38）和最差（W=252，$R^2$=0.26）仅相差0.12。
- **W=120（约6个月）总体最优**：这在拥有足够的历史背景来捕捉市场趋势和避免引入过时、无关数据之间取得了平衡。6个月大致对应两个财报周期，能够捕捉到有意义的基本面信号。
- **W=30在H=1时颇具竞争力（$R^2$=0.63）**：对于次日预测，近期数据最具参考价值。30天窗口捕捉了当前的市场微观结构，而不受更早的、可能无关的数据干扰。
- **W=252（1年）表现最差，尤其在H=10时（$R^2$=-0.10）**：一整年的回望引入了可能反映不同市场环境的旧数据，使模型产生混淆。这在误差累积已经很高的长步长预测中尤为严重。
- **W=90略有不足**：这可能对应一个尴尬的中间地带，窗口捕捉了不完整的季度周期，引入了来自不完整财报期的噪声。

## 3.3 各模型对窗口大小的敏感性

| 模型 \ 窗口 | W=30 | W=60 | W=90 | W=120 | W=252 |
|---|---|---|---|---|---|
| ARIMA | 0.7362 | 0.7492 | 0.7507 | 0.7569 | 0.7576 |
| Bi-RNN | 0.6821 | 0.6882 | 0.6493 | 0.6668 | 0.4651 |
| Bi-GRU | 0.6384 | 0.6127 | 0.6269 | 0.6046 | 0.4312 |
| Bi-LSTM | 0.5495 | 0.4797 | 0.2776 | 0.5377 | 0.5542 |
| Mamba | 0.6413 | 0.5861 | 0.6742 | 0.6737 | 0.6082 |
| PatchTST | -0.6740 | -0.6510 | -0.6579 | -0.7952 | -1.0214 |
| SNN | -0.0092 | -0.1731 | -0.3115 | -0.0154 | -0.4455 |
| Ensemble | 0.5840 | 0.5760 | 0.5655 | 0.5868 | 0.5329 |

**分析解读**：

- **ARIMA随窗口大小单调递增**：更多数据有助于ARIMA更准确地估计自回归系数，因为它依赖于统计参数估计。
- **深度学习模型普遍偏好较短窗口（W=30~120）**：
  - **Bi-RNN**：在W=252时急剧退化（0.47 vs W=30时的0.68），表明它无法从一整年的数据中有效过滤相关信号。

- **Bi-GRU**：与Bi-RNN模式相似，W=30为最优。
- **Mamba**：在W=90-120处达到峰值，与其状态空间架构选择性保留长程模式而不被噪声淹没的能力一致。

- **PatchTST随窗口增大而持续恶化**：其基于patch的方式在更大窗口下会产生更多的token，可能导致注意力稀释。

---

# 4. 各时期详细分析

## 4.1 2008年金融危机 (2007-10 至 2009-03)

| 模型 | H=1 | H=5 | H=10 | 平均 |
|---|---|---|---|---|
| ARIMA | 0.9902 | 0.9676 | 0.9394 | **0.9657** |
| Bi-GRU | 0.9864 | 0.9483 | 0.8967 | 0.9438 |
| Bi-LSTM | 0.9730 | 0.9489 | 0.9006 | 0.9409 |
| Mamba | 0.9777 | 0.9333 | 0.9019 | 0.9376 |
| Bi-RNN | 0.6537 | 0.9354 | 0.5878 | 0.7256 |
| Ensemble | 0.8782 | 0.8382 | 0.8047 | 0.8404 |
| SNN | 0.4154 | 0.7586 | 0.4975 | 0.5572 |
| PatchTST | 0.1760 | -0.6839 | 0.2173 | -0.0968 |

**分析**：所有主流模型都取得了优异的表现（ARIMA、Bi-GRU、Bi-LSTM、Mamba的$R^2$均超过0.90）。2008年危机具有强烈的持续性下行趋势和高自相关性，非常适合时间序列模型。充足的样本量（378）和持续的方向性趋势使模型能够学习到主导模式。值得注意的是，Bi-RNN在H=1时出现了异常低的分数（0.65），这可能是由于其无法捕捉危机高峰期复杂的日内波动聚集现象，但在H=5时表现良好（0.94），因为此时主导趋势重新确立。

## 4.2 2010年欧债危机 (2010-04 至 2012-06)

| 模型 | H=1 | H=5 | H=10 | 平均 |
|---|---|---|---|---|
| ARIMA | 0.9744 | 0.8831 | 0.8112 | **0.8896** |
| Mamba | 0.9601 | 0.8684 | 0.8054 | 0.8780 |
| Bi-RNN | 0.9559 | 0.8708 | 0.8301 | 0.8856 |
| Bi-LSTM | 0.9633 | 0.8729 | 0.7900 | 0.8754 |
| Bi-GRU | 0.9639 | 0.4772 | 0.5143 | 0.6518 |
| Ensemble | 0.8544 | 0.7344 | 0.7102 | 0.7663 |
| SNN | 0.1308 | 0.5713 | 0.4405 | 0.3809 |
| PatchTST | -0.5093 | -1.6243 | -0.9004 | -1.0113 |

**分析**：欧债危机拥有最大的样本量（568天）和相对温和的波动性（所有时期中最低的RMSE=0.0096），创造了有利的学习条件。大多数深度学习模型在H=1时表现相当（均在0.96左右）。异常之处在于Bi-GRU在H=5时的急剧下降（0.48），这暗示可能对短程模式过拟合，导致在该特定时期的中期预测中无法泛化。

## 4.3 2015年中国股灾 (2015-06 至 2016-02)

| 模型 | H=1 | H=5 | H=10 | 平均 |
|---|---|---|---|---|
| ARIMA | 0.9130 | 0.5869 | 0.3015 | **0.6005** |
| Bi-RNN | 0.8305 | 0.4766 | 0.3939 | 0.5670 |
| Bi-GRU | 0.8613 | 0.5739 | 0.2302 | 0.5551 |
| Bi-LSTM | 0.8240 | 0.5588 | 0.2032 | 0.5287 |
| Mamba | 0.8997 | 0.5548 | 0.0807 | 0.5117 |
| Ensemble | 0.7533 | 0.5128 | 0.2649 | 0.5103 |
| SNN | -0.0419 | -0.0079 | -0.0766 | -0.0422 |
| PatchTST | -1.2353 | -2.5181 | -0.7911 | -1.5148 |

**分析**：与早期危机相比，性能显著下降。中国股灾对SP500的影响是通过复杂的跨市场传染渠道（资本流动、大宗商品价格、汇率市场）传导的，而非国内基本面因素。这种间接传导产生了嘈杂、非平稳的模式。较小的样本量（189）加剧了这一问题。Mamba在H=1时表现出色（0.90），因为其能够建模快速的传染动态，但在H=10时崩溃（0.08），因为这些动态在更长的时间范围内变得不可预测。

### 4.4 2018年贸易战 (2018-01 至 2018-12)

| 模型 | H=1 | H=5 | H=10 | 平均 |
|---|---|---|---|---|
| ARIMA | 0.9084 | 0.5851 | 0.2500 | **0.5812** |
| Mamba | 0.8744 | 0.4903 | 0.1470 | 0.5039 |
| Bi-RNN | 0.7591 | 0.4131 | 0.2654 | 0.4792 |
| Bi-GRU | 0.8089 | 0.3991 | -0.1310 | 0.3590 |
| Ensemble | 0.7638 | 0.4478 | 0.0899 | 0.4338 |
| SNN | 0.3853 | -0.0209 | -0.5355 | -0.0570 |
| Bi-LSTM | 0.7228 | 0.2963 | -1.3358 | -0.1056 |
| PatchTST | -0.4435 | -0.3369 | -1.0446 | -0.6083 |

**分析**：贸易战由外生性政治冲击（关税公告、贸易谈判）驱动，这些冲击从历史价格数据中根本无法预测。这代表了一个典型的"新闻驱动型"市场案例，技术性模型在此类市场中表现不佳。Bi-LSTM在H=10时的灾难性表现（-1.34）表明对短期模式的严重过拟合，这些模式在10天窗口内因新的贸易战进展改变市场方向而发生反转。Mamba在深度学习模型中表现最佳，可能是因为其选择性门控能够快速适应政策体制变化。

### 4.5 2020年新冠崩盘 (2020-02 至 2020-06)

| 模型 | H=1 | H=5 | H=10 | 平均 |
|---|---|---|---|---|
| ARIMA | 0.8896 | 0.6057 | 0.2216 | **0.5723** |
| Bi-RNN | 0.7639 | 0.5068 | -0.1485 | 0.3740 |
| Ensemble | 0.6961 | 0.3996 | -0.2448 | 0.2836 |
| Bi-LSTM | 0.6573 | 0.3490 | -0.3436 | 0.2209 |
| Bi-GRU | 0.7132 | 0.3027 | -0.3812 | 0.2116 |
| Mamba | 0.6830 | 0.3249 | -0.7330 | 0.0917 |
| SNN | -0.1103 | -0.2828 | -1.0407 | -0.4779 |
| PatchTST | -0.2655 | -0.8587 | -1.0644 | -0.7295 |

**分析**：对所有模型来说最具挑战性的时期。新冠疫情引发了一次史无前例的"黑天鹅"事件：史上最快的熊市（23天内下跌34%），随后是同样史无前例的反弹，由大规模财政/货币刺激推动。仅有104个样本且具有极端非平稳性，基于历史数据训练的模型没有可参考的类似模式。在H=10时，每一个深度学习模型的$R^2$都为负值，意味着它们全部不如简单地预测均值。Mamba尽管是总体最佳的深度学习模型，在此处却特别挣扎（H=10时为-0.73），表明其状态空间机制记住了崩盘前的动态，而这些动态在恢复阶段变得完全无关。

## 4.6 2022年加息周期 (2022-01 至 2022-12)

| 模型 | H=1 | H=5 | H=10 | 平均 |
|---|---|---|---|---|
| ARIMA | 0.9512 | 0.7861 | 0.5941 | **0.7771** |
| Mamba | 0.9042 | 0.7593 | 0.4949 | 0.7195 |
| Bi-RNN | 0.8878 | 0.5750 | 0.4695 | 0.6441 |
| Ensemble | 0.8407 | 0.6587 | 0.3216 | 0.6070 |
| Bi-GRU | 0.8590 | 0.6143 | 0.1506 | 0.5413 |
| Bi-LSTM | 0.7627 | 0.5892 | 0.1882 | 0.5133 |
| SNN | 0.3362 | 0.2319 | 0.1835 | 0.2505 |
| PatchTST | -1.2229 | -1.5877 | -2.8135 | -1.8747 |

**分析**：2022年加息周期创造了一个结构性驱动的熊市，市场走势与美联储通讯和经济数据发布（CPI、就业数据）紧密耦合。这使得市场更加"制度化"——鹰派信号后出现抛售期，鸽派暗示时出现缓解性反弹。Mamba在此处表现优异（最佳深度学习模型，$R^2$=0.72），可能是因为其状态空间机制能够建模美联储行动与市场反应之间的条件性制度动态。PatchTST在所有时期中表现最差（-1.87），证实了其根本不适合政策敏感型金融数据。

## 4.7 2023年AI浪潮 (2023-01 至 2023-12)

| 模型 | H=1 | H=5 | H=10 | 平均 |
|---|---|---|---|---|
| ARIMA | 0.9758 | 0.8756 | 0.7422 | **0.8645** |
| Bi-GRU | 0.9495 | 0.8339 | 0.6662 | 0.8165 |
| Mamba | 0.9561 | 0.8327 | 0.6554 | 0.8147 |
| Bi-RNN | 0.8699 | 0.7876 | 0.5523 | 0.7366 |
| Ensemble | 0.7286 | 0.5704 | 0.3184 | 0.5391 |
| Bi-LSTM | 0.8619 | 0.5602 | -0.2682 | 0.3847 |
| PatchTST | 0.3778 | -0.0192 | 0.3503 | 0.2363 |
| SNN | -1.8006 | -1.1323 | -1.5945 | -1.5091 |

**分析**：2023年由AI驱动的牛市对大多数模型来说相对可预测。由持续的AI投资叙事驱动的强劲上升趋势为趋势跟随型模型创造了有利条件。这是PatchTST唯一取得正$R^2$（0.24）的时期，表明它在市场具有明确方向性偏差时能够捕捉较长程的趋势性模式。然而，SNN在此处的整体表现最差（-1.51），说明基于二值脉冲的计算根本无法表征AI热潮所特有的平滑、持续性上升趋势。

# 5. 综合洞察

## 5.1 趋势驱动型 vs 事件驱动型时期

结果揭示了一个清晰的二分格局：

| 类别 | 时期 | 平均$R^2$ | 特征 |
|---|---|---|---|
| **趋势驱动型** | 2008金融危机、2010欧债危机、2023 AI浪潮 | **0.54** | 持续性方向运动，高自相关性 |
| **事件驱动型** | 2018贸易战、2020新冠、2015中国股灾 | **0.16** | 外生性冲击，制度变化，低可预测性 |
| **混合型** | 2022加息周期 | 0.27 | 政策驱动伴随结构性断点 |

模型在趋势驱动型时期的表现大约是事件驱动型时期的**3.4倍**（按$R^2$计算）。这与有效市场假说一致：趋势驱动型时期具有更强的序列相关性，统计模型可以利用这一点；而事件驱动型时期更接近随机游走行为。

## 5.2 预测步长-模型复杂度的权衡

| 模型复杂度 | H=1最佳 | H=10最佳 | 解读 |
|---|---|---|---|
| 低（ARIMA、Bi-RNN） | 有竞争力 | **胜出** | 简单模型在长步长预测中泛化能力更强 |
| 中（Bi-GRU、Mamba） | **胜出** | 有竞争力 | 最适合短到中期预测 |
| 高（PatchTST、SNN） | 最差 | 最差 | 对此任务而言过于复杂 |

这展示了**偏差-方差权衡**的实际运作：高复杂度模型在短步长下捕获更多信号，但在长步长下因过拟合而累积更多误差。

## 5.3 模型架构适用性总结

| 模型 | 优势 | 劣势 | 最佳应用场景 |
|---|---|---|---|
| **ARIMA** | 总体精度最高，最稳定，各步长均为最佳 | 无法建模非线性关系，不可端到端学习 | 基准模型；H=1生产环境使用 |
| **Mamba** | 深度学习中H=1最佳，在制度驱动型市场表现出色（2022、2023） | 在极端事件中退化（新冠） | 结构性市场中的短期预测 |
| **Bi-RNN** | 最稳定的深度学习模型，H=10时深度学习中最佳 | 峰值性能较低 | 长步长预测，高波动市场 |
| **Bi-GRU** | 短步长表现强劲，趋势型市场中表现良好 | 在H=5/10时不一致（如欧债危机异常） | 趋势型市场中的短期预测 |
| **Bi-LSTM** | 在明确的危机中表现良好（2008、2010） | 在H=10时有严重过拟合风险 | 仅在趋势明确的时期使用 |
| **Ensemble** | 表现适中且一致 | 被表现差的成分模型拖累 | 不推荐，除非经过模型筛选 |
| **PatchTST** | 仅在趋势性的2023年获得微弱正$R^2$ | 7个时期中6个为负$R^2$ | 不适合金融时间序列 |
| **SNN** | 偶尔在危机时期有用 | 极度不稳定，$R^2$大多为负 | 不推荐 |

## 5.4 核心结论

1. **ARIMA是无可争议的冠军**：在所有特殊时期的SP500指数预测中均排名第一。其统治地位表明，SP500的自相关结构是最强的预测信号，统计方法比神经网络更高效地利用了这一点。
2. **深度学习中，Mamba和Bi-RNN构成最优组合**：Mamba适用于正常至结构化市场中的短期预测（H=1），Bi-RNN适用于更长步长（H=5、H=10）或高波动条件下，此时简单性有助于泛化。
3. **预测步长比任何其他因素都更重要**：$R^2$从H=1（0.57）到H=10（0.10）的下降幅度远超模型选择、窗口大小或市场时期的影响。这表明改善长步长预测需要根本性的不同方法（如引入外部数据、制度检测），而非仅仅改进模型架构。
4. **黑天鹅事件从根本上不可预测**：2020年新冠崩盘表明，任何程度的历史模式学习都无法让模型为真正史无前例的事件做好准备。风险管理策略不应在极端市场条件下仅依赖模型预测。
5. **窗口大小是次要因素**：W=120略微最优，但不同窗口之间的差异很小。从业者应优先考虑模型选择和预测步长校准，而非窗口调优。

---

*报告基于 SpecialPeriod_Seed2620 实验数据生成。*